

## TP1 : Prise en main de R

---

**Objectifs de la séance :** *Commencer à utiliser le logiciel comme une calculatrice et savoir faire quelques manipulations élémentaires sur une série de données rangées dans un vecteur. Savoir tracer le graphe d'une fonction. Savoir charger des données.*

R est un logiciel libre développé par une très large communauté scientifique et basé sur "des objets". RStudio est une interface très pratique pour utiliser simplement les fonctionnalités de R. Rstudio est installé sur les machines du DLST. Pour travailler sur votre ordinateur perso, vous pouvez télécharger R et RStudio sur <https://posit.co/download/rstudio-desktop/>.

RStudio est séparé en 4 fenêtres graphiques :

- en bas à gauche : fenêtre de commandes où sont exécutées les instructions tapées après le prompt `>` avec la touche retour chariot du clavier (Entrée  $\leftrightarrow$ ).
- en haut à gauche : où l'on écrit son script afin de pouvoir sauver ses instructions dans un fichier `nomfichier.R`.
- en bas à droite : où sont, entre autres, affichés les graphiques.
- en haut à droite : indique l'historique des instructions exécutées pendant la session, affiche les objets créés au fur et à mesure en précisant leur nature.

Vous trouverez sur la "toile" un grand nombre de cours ou "tutorials" et bien sur vous avez toujours à votre disposition l'aide en ligne de R que l'on pourra appeler avec la fonction `help()`. Attention, dans le langage R, on distingue majuscule et minuscule.

## 1 Documents de cours

Tous les documents de TP sont disponibles sur Chamilo dans le cours Statistiques et Calcul des probabilités - STA401, répertoire Documents/Doc-TP.

Avant toute chose créer dans son dossier personnel un répertoire TPSTAT et des sous-répertoires Data, TP1, ..., TP10 dans lesquels seront rangés tous les documents de TPs.

Aller sur Chamilo et télécharger (en cliquant sur la disquette bleue et sans les ouvrir dans Chamilo) les fichiers de données rangés dans le répertoire Données-TP et les ranger dans le sous-répertoire Data du dossier personnel. Récupérer l'énoncé du TP1 dans le répertoire TP-énoncés et le ranger dans TP1.

## 2 Premiers pas avec R et l'environnement RStudio :

Une fois R (R.base) et Rstudio installés sur la machine une icône R est disponible sur le bureau. Cliquer sur cette icône et l'environnement de RStudio s'ouvre et se présente avec trois ou quatre fenêtres.

### Exercice 1 : méthode de travail

1. Lancer RStudio
2. Ouvrir un nouveau script en allant dans **File > New file > Rscript** : la quatrième fenêtre en haut à gauche s'ouvre.
3. Commencer par y inscrire en ligne 1 le commentaire : `#-----Exercice 1-----` puis exécuter cette ligne de commande en cliquant sur le numéro de ligne du script indiqué à l'extrémité gauche de la ligne (la sélection de la ligne à exécuter est surlignée en bleue) et cliquer sur l'onglet **Run**. Observer la sortie retournée par R en bas à gauche. Comme la ligne est précédée du signe `#`, R voit la suite comme un commentaire et l'affiche.
4. Taper à présent la ligne de commande `1:10` et l'exécuter. Que retourne R ?
5. Nommer la séquence précédente `init` avec :  
`init<-1:10`  
ou `1:10->init` ou encore `init=1:10`. Observer ce qui s'affiche en haut à droite. Pour afficher le contenu de l'objet appelé `init` dans la fenêtre de commande en bas à gauche il suffit d'exécuter la commande :  
`init`
6. A tout moment pour comprendre ce que fait une fonction ou une commande il suffira d'appeler l'aide de R avec la fonction `help()`. Par exemple  
`help(":")`  
retourne les instructions pour utiliser l'opérateur `:`.
7. Sauvegarder votre script en activant la fenêtre où est affichée le script (il suffit de cliquer dans la fenêtre et le curseur clignote) puis aller dans **File > Save as** puis taper TP1 (inutile de rajouter l'extension `.R` qui sera automatiquement ajoutée puisqu'il s'agit d'un script ouvert avec RStudio).
8. Fermer RStudio qui propose alors une sauvegarde du Workspace qui n'est pas indispensable puisque toutes les instructions sont conservées dans le script précédemment sauvegardé.

## 3 Les vecteurs et les matrices

L'objet élémentaire est le vecteur constitué d'une suite de mots (de type alpha-numériques) d'éléments logiques (TRUE ou FALSE) ou de nombres (de type numériques). Une collection de vecteurs de mêmes types et de mêmes longueurs constitue une matrice.

### Exercice 2 : créer, manipuler des vecteurs ou des matrices

1. Relancer RStudio, sélectionner le répertoire de travail TP1 et ouvrir le script TP1.R
2. *Créer* : la suite de données (1,2,3,4,5) en tapant la commande `c(1,2,3,4,5)` puis en l'exécutant avec Entrée ↵:

`c(.)` est la fonction de concaténation qui permet de créer une suite d'éléments (logiques, numériques ou alpha-numériques) énoncés les uns à la suite des autres et séparés par des virgules. L'objet ainsi produit est un vecteur colonne.

Ici la réponse de R est `[1] 1 2 3 4 5` qui indique que l'objet ainsi créé est constitué d'une colonne numérotée `[1]` et qui contient la suite des valeurs `(1, 2, 3, 4, 5)` (par souci d'ergonomie ces valeurs sont listées sur une seule ligne).

3. *Affecter* : la suite précédemment créée dans un vecteur nommé `x` en exécutant la commande : `x <- c(1,2,3,4,5)` (ou bien `x -> c(1,2,3,4,5)`). R ne retourne rien sinon le traditionnel début de ligne `>` pour vous redonner la main. C'est normal et si vous voulez vérifier que le vecteur `x` existe bien quelque part et contient les informations saisies il vous suffit de l'appeler en exécutant seulement  
`x`
4. *Extraire* : Exécuter  
`x[2]` # pour obtenir l'élément d'indice 2 du vecteur `x` et  
`x[c(2,4)]` # pour obtenir les éléments d'indices 2 et 4.  
Que fait la commande  
`x[-2]` ?
5. Fabriquer le vecteur `y` contenant la suite des valeurs `(2, 4, 6, 8, 10)` et le vecteur `label` contenant la suite de caractères `a,b,c,d,e` avec `label<-c("a","b","c","d","e")`.
6. *Créer une matrice* avec 5 lignes et 2 colonnes contenant `x` et `y` en l'affectant à `A` avec :  
`A <- matrix(c(x,y),ncol=2,byrow=F)`  
Consulter l'aide de la fonction `matrix` et indiquer ce que fait l'option `nrow`. On peut aussi utiliser la commande `cbind`:  
`cbind(x,y)`.
7. *Extraire ou compléter* : comme pour les vecteurs on peut extraire des éléments d'une matrice ou construire une matrice à partir de plusieurs autres matrices ou vecteurs. Que font les commandes :  
`A[1,2]`  
`A[,1]`  
`A[2,]`  
et commenter les deux commandes suivantes  
`un <- rep(1,5)`  
`B <- matrix(c(x,y,un),ncol=3,byrow=F)`

## 4 Calculer avec R : manipulations de base

Il s'agit là d'expérimenter les calculs élémentaires que l'on doit savoir faire avec un ou plusieurs vecteurs numériques de même longueur ou une ou plusieurs matrices de mêmes dimensions.

### Exercice 3 : Avec un seul vecteur

1. *Multiplier ou diviser par un scalaire* : Par exemple pour produire le résultat du calcul  $\frac{1}{5}(1, 2, 3, 4, 5)$  (resp. du calcul  $5 * (1, 2, 3, 4, 5)$ ) on exécutera :  
`x/5` (resp. `x*5`)
2. *Ajouter un scalaire* : par exemple pour calculer  $(1 + 2, 2 + 2, 3 + 2, 4 + 2, 5 + 2)$  on exécute :  
`x+2`
3. *Sommer en cumulant ou pas* : on obtient la somme des éléments de `x` (resp. les sommes cumulées) avec la fonction `sum()` (resp. `cumsum()`) :  
`sum(x)`  
`cumsum(x)`
4. *Dimension* : on obtient la longueur de `x` avec la fonction `length`  
`length(x)`

5. *Calculer la racine* : avec la fonction `sqrt()`  
`sqrt(x)`
6. *Calculer une puissance* : avec le symbole `^`, par exemple :  
`x ^ 3`
7. *Agrandir* (ajouter des éléments à la liste décrite par un vecteur) : si on veut produire un vecteur  $x'$  constitué de  $x$  complété par une sixième valeur 6 par exemple on utilise la fonction de concaténation `c()` :  
`c(x,6)`  
Si on veut compléter  $x$  par (1, 1, 1, 1, 1) on peut utiliser l'une ou l'autre des commandes suivantes :  
`c(x,1,1,1,1,1)`  
`c(x,rep(1,5))`  
`c(x,c(1,1,1,1,1))`  
La fonction `rep()` permet de créer une suite d'éléments de même valeur (premier argument) et de longueur (deuxième argument) fixées. Essayer également de manipuler la fonction `seq()`, bien utile en pratique. Tester par exemple les commandes :  
`seq(1,10,2)`  
`seq(from=1,to=10,by=2)`  
`seq(from=1,to=2,by=.2)`
8. *Tester* : Si on souhaite savoir si les composantes de  $x$  vérifient une condition logique par exemple si elles sont positives on exécute :  
`x>0`  
Si on veut savoir pour quel indices les composantes de  $x$  sont positives on exécute :  
`which(x>0)`
9. Que fait la commande :  
`length(which(x>0))`
10. Que font les commandes :  
`which(x!=2)`  
`x>0&x<2`  
`sum(x>0&x<2)`

#### Exercice 4 : Avec plusieurs vecteurs

1. *Ajouter des vecteurs* : pour ajouter (ou soustraire)  $x$  et  $y$  (l'élément en position  $i$  du résultat est la somme des éléments en position  $i$ , de  $x$  et de  $y$ ) on exécute : `x+y` ou `x-y`
2. *"Multiplier des vecteurs"* : pour multiplier (ou diviser) deux à deux les éléments des vecteurs  $x$  et  $y$  (attention il ne s'agit pas de la multiplication matricielle usuelle entre un vecteur ligne et un vecteur colonne ou entre un vecteur colonne et un vecteur ligne) :  
`x*y` ou `x/y`
3. *Réunir deux vecteurs* : dans un même vecteur colonne avec la fonction `c()` ou dans une matrice à cinq lignes et deux colonnes (une pour  $x$  et l'autre pour  $y$ ) avec la fonction `cbind()` ou dans une matrice à 2 lignes et cinq colonnes avec `rbind()`. Tester les commandes:  
`cbind(x,y)`  
`rbind(x,y)`  
`t(cbind(x,y))`  
Que fait la fonction `t()` ?

#### Exercice 5 : pour s'entraîner

1. Calculer la moyenne empirique ( $\bar{x}$ ) et la variance empirique ( $s^2 = \bar{x^2} - \bar{x}^2$ ) de  $x$
2. Calculer la proportion des coordonnées de  $x$  inférieures ou égale à 2.
3. Calculer le nombre de fois où la  $i$ ème coordonnée de  $x$  dépasse la  $i$ ème coordonnée de  $y$

## 5 Graphiques

Avec R il est possible de superposer des couches graphiques les unes sur les autres. Certaines fonctions graphiques sont des fonctions "primaires" qui permettent de créer une première couche graphique (par ex `plot()`, `boxplot()`, `hist()`, `curve()`...), d'autres sont des fonctions "secondaires" qui permettent de rajouter des éléments sur la première couche comme par exemple une droite (avec `abline()`), un point ou une collection de points (avec `points()`), une courbe supplémentaire (avec `curve(...,add=T)`), une légende (avec `legend()`)...

Il est recommandé de toujours lire l'aide fournie par R sur la fonction utilisée qui indique les arguments minimum à fournir ainsi que les options proposées. Parmi les options possibles, savoir utiliser les suivantes :

- `main="mon titre"` : pour inclure le titre "mon titre"
- `xlab="abscisses"` : pour mettre la légende "abscisses" sous l'axe des abscisses (idem pour `ylab`)
- `xlim=c(a,b)` : pour imposer l'intervalle  $[a, b]$  comme limites de l'axe des abscisses (idem pour `ylim`)
- `type` : pour caractériser le type de tracé dans `plot()`
- `asp` : pour définir le ratio entre l'unité en abscisse et l'unité en ordonnée
- `col` : pour définir la couleur
- `pch` : pour définir le caractère utilisé pour représenter un point.
- `lty` : pour définir le type de trait dans un tracé (plein, pointillé,...)
- `lwd` : pour définir l'épaisseur du trait

Ne pas oublier que sans spécifications de certains arguments ou options, R fera un choix par défaut (indiqué dans l'aide).

### Exercice 6 : tracé d'une fonction.

Soit la fonction  $f(x) = \sin(x)$ . On se propose ici de tracer son graphe sur  $[0, 7]$ .

1. Créer le vecteur des nombres allant de 0 à 7 par pas de 0.1 et le nommer `abs`
2. Créer le vecteurs des ordonnées obtenues en appliquant la fonction `sin` aux abscisses listées dans `abs` et les affecter à `ord`
3. Tracer le graphe de  $f$  sur  $[0, 7]$  en utilisant la fonction `plot()`. Il est fortement recommandé de consulter au préalable l'aide en ligne de cette fonction. Ajouter titre et légendes. Refaire ce graphique à l'aide de la fonction `curve(sin)`.
4. Ajouter la droite d'équation  $y = 1$  en rouge, celle d'équation  $y = x$  en vert et les axes des abscisses et ordonnées en noir avec la fonction `abline()`.
5. Ajouter le point de coordonnées (3,1) sur le graphique précédent avec la fonction `points()`.
6. Ajouter le tracé de la fonction `cos` sur le même graphique en utilisant la fonction `curve()` et l'option `add=TRUE`.

## 6 Chargement de données

### Exercice 7 :

Utiliser la fonction `read.table` pour charger des données.

1. Pour pouvoir lire les données que vous avez téléchargé de Chamillo et placé dans un répertoire **Data**, vous devez soit donner le lien complet vers l'emplacement de vos données (par exemple `read.table("mypathستا401/Data/apnee.csv")`), soit indiquer à R dans quel répertoire vous voulez travailler par défaut. Pour cette dernière option, aller dans le menu du bandeau supérieur **Session > Set Working Directory > Choose directory** puis sélectionner votre répertoire **Data** (ne pas oublier de sélectionner le répertoire choisi en cliquant sur ouvrir). C'est équivalent à écrire dans la console `setwd("mypathستا401/Data")`. Vous pourrez alors utiliser juste `read.table("apnee.csv")`.
2. L'instruction `apnee <- read.table("apnee.csv")` permet-elle de charger correctement les données du fichier `apnee.csv` ? Pour vérifier, regardez les premières lignes avec la commande `head(apnee)`. Sinon ajouter l'option `sep=","` pour définir le séparateur de champs de ce fichier et `header=T` pour indiquer que la première ligne du fichier contient les noms de colonnes (par défaut R considère que `header=F` et lit la première ligne du fichier comme le premier individu observé). Une fois les données correctement chargées, les affecter dans un `data.frame` nommé `apnee`. Dans la fenêtre en haut à droite, vérifier que les dimensions du `data.frame` `apnee` sont correctes (nombre de colonnes 8 et de lignes 100). Que retourne la commande `summary(apnee)` ?
3. Charger les données du fichier `cardiaque.csv` et les affecter à `cardiaque`. Que retourne `cardiaque$tabac` ?
4. Charger les données du fichier `her.txt` et les affecter à `her`. Que retournent les instructions `her[3,2]`; `her[,2]`, `her[3,]` ? Calculer la moyenne empirique de l'échantillon de la variable `sex`. Que représente cette valeur (`sex` prend la valeur 0 pour les hommes et 1 pour les femmes) ?

Notez la présence dans Chamilo Données-TP du fichier `chargementData.R` qui montre comment charger les différentes données utilisées lors des TP suivants.