

TP4 : Quantiles-quantiles plots et droite de Henry

Exercice pour l'extraction de données : Charger le jeu de données `cardiaque.csv` et l'affecter à `cardiaque`. En extraire l'échantillon des pressions systoliques chez les patients souffrant d'une pathologie cardiaque (modalité 1 de la variable `cardiaque`) et en donner les résumés numériques usuels : taille, moyenne, écart-type empirique corrigé (noté s' dans le cours) et quantiles.

Objectifs : *Savoir apprécier graphiquement la normalité ou non d'une suite d'observations d'une variable X à l'aide d'un histogramme ou d'un quantile-quantile plot accompagné de la droite de Henry.*

Dans cette partie X est une variable aléatoire de loi $\mathcal{N}(2, 4)$ (soit $\mu=2$, $\sigma = 2$).

Exercice 1 : quantiles empiriques ou théoriques

Le quantile empirique d'ordre α d'un échantillon de n tirages indépendants x_1, x_2, \dots, x_n de X est la valeur pour laquelle, la proportion des x_i qui se trouvent inférieurs ou égaux à cette valeur, vaut α . Le quantile théorique d'ordre α appelé quantile (et calculé par la fonction de quantile `qnorm()`) est la valeur telle que la probabilité que X soit inférieur ou égal à cette valeur, vaille α .

1. Simuler un échantillon de taille $n = 50$ de X et l'affecter à `x`.
2. Calculer les quantiles empiriques d'ordre 10%, 20%, ..., 90% de `x` (appelés aussi les déciles empiriques car ils permettent de couper l'échantillon en dix) à l'aide de la fonction `quantile()` et en utilisant l'option `type=1`.
3. Calculer les quantiles théoriques d'ordre 10%, 20%, ..., 90% de X à l'aide de la fonction `qnorm()`.
4. Faire un graphe des 9 points d'abscisses les déciles et d'ordonnées les déciles empiriques. Ajouter la droite $y = x$. Commentaire.
5. Faire un histogramme des observations tirées et y superposer la densité de la loi $\mathcal{N}(2, 4)$. Commentaire.
6. Calculer les quantiles empiriques d'ordre $1/(n+1), 2/(n+1), \dots, n/(n+1)$ de `x`. Les comparer aux valeurs ordonnées de l'échantillon que l'on obtiendra avec la commande `sort(x)`.
7. Calculer les quantiles théoriques d'ordre $1/(n+1), 2/(n+1), \dots, n/(n+1)$ de X et tracer les points d'abscisses quantiles théoriques et ordonnées quantiles empiriques. Y ajouter la droite $y = x$.
8. Calculer les quantiles théoriques d'ordre $1/(n+1), 2/(n+1), \dots, n/(n+1)$ de la loi normale centrée réduite. Tracer les quantiles empiriques en fonction de ces nouveaux quantiles théoriques. Y ajouter la droite d'équation $y = \sigma x + \mu$ pour $\mu = 2$ et $\sigma = 2$. Cette droite s'appelle droite de Henry et permet d'apprécier la normalité d'un échantillon x_1, \dots, x_n . Plus les points sont proches de la droite plus l'hypothèse de normalité faite sur la variable qui a généré ces observations est correcte.
9. Comparer le graphique précédemment obtenu avec le résultat de la commande `qqnorm(x)`. La commande `qqline(x)` permet-elle d'ajouter la droite de Henry ? Si non comment est construite cette droite ?

Exercice 2 : diagnostiquer la normalité de données par un qqplot

Le but ici est de comprendre comment interpréter des échantillons pour lesquels les points représentés ne sont pas alignés autour de la droite de Henry.

1. Choisir une valeur pour n (supérieure à 100) et l'affecter à `n`.
2. Simuler un échantillon de taille n de la loi uniforme sur $[-1, 1]$ avec la fonction `runif` et l'affecter à `x`. Rappeler son espérance que l'on notera μ et sa variance σ^2 . Tracer le nuage des points croisant quantiles théoriques et quantiles empiriques avec `qqnorm(x)` et y superposer la droite de Henry obtenue avec `qqline(x)`. Interpréter.
3. Simuler un échantillon de taille n de la loi de Student de paramètre 3 avec la fonction `rt` et refaire le même graphique que dans la question précédente. Pour aider l'interprétation, tracer sur un même graphe la densité de la loi $\mathcal{N}(0, 1)$ et celle de la Student à 3 degrés de liberté. Interpréter.
4. Refaire la même chose avec un échantillon de taille n de la loi du Chi-deux de paramètre 2 avec la fonction `rchisq`. Commenter.