

TP7 : Introduction aux tests paramétriques

Objectifs : Appliquer une règle de décision et savoir l'ajuster de sorte que le risque de première espèce α (celui de refuser à tort l'hypothèse nulle testée) ait une valeur spécifiée à l'avance. On dira que l'on met en oeuvre un test de niveau (ou seuil) α . Comprendre la p-valeur d'un test. Exercices sur données simulées et sur données réelles `apnee.csv`.

1 Données simulées

Exercice 1 :

On utilisera dans cet exercice des données simulées sous une loi normale $\mathcal{N}(\mu, \sigma^2)$.

1. Définir $\mu = 2$, $\sigma = 1$, $N = 1000$ et $n = 50$. Générer N tirages d'échantillons de taille n pour une variable de $\mathcal{N}(\mu, \sigma^2)$ et les affecter à `dataG`, matrice de N lignes et n colonnes.
2. Calculer N moyennes \bar{x}_n en utilisant la fonction `apply` ou `rowMeans`.
3. Vérifiez graphiquement que \bar{x}_n suit une loi normale $\mathcal{N}(\mu, \sigma^2/n)$
4. On souhaite effectuer le test statistique suivant pour une valeur μ_0 donnée :

$$\mathcal{H}_0 : \mu = \mu_0 \qquad \mathcal{H}_1 : \mu > \mu_0$$

On propose plusieurs tests possibles pour décider entre ces deux hypothèses à l'aide d'un échantillon de X .

- Test 1 : refus de \mathcal{H}_0 lorsque $\bar{x}_n > \mu_0$
- Test 2 : refus de \mathcal{H}_0 lorsque $\bar{x}_n > \mu_0 + 2/\sqrt{n}$
- Test 3 : refus de \mathcal{H}_0 lorsque $\bar{x}_n > \mu_0 + 3/\sqrt{n}$

Evaluer pour chacun des trois tests proposés la fréquence avec laquelle sera conclue l'hypothèse \mathcal{H}_1 sur les N échantillons tirés, lorsque l'on teste la valeur $\mu_0 = 2$. Que représentent ces fréquences ainsi calculées ?

5. On suppose $\sigma = 1$. Proposer un test (refus de \mathcal{H}_0 lorsque $\bar{x}_n > C_\alpha$) pour lequel le risque d'accepter \mathcal{H}_1 à tort soit de valeur $\alpha = 5\%$ et vérifier que cette nouvelle règle de décision se trompe approximativement $0.05N = 50$ fois parmi les $N = 1000$ échantillons tirés.
6. reformuler ce même test avec la statistique de test T centrée et normalisée.
7. Calculer les p-valeurs correspondantes. Rappel: la p-valeur est le α^* pour lequel $C_{\alpha^*} = \bar{x}_n$, c'est à dire $\alpha^* = P_{\mathcal{H}_0}(\bar{X} > \bar{x}_n)$. Faire un histogramme de ces p-valeurs. Quelle semble être la loi que suit la p-valeur lorsque H_0 est vrai ? En déduire que la p-valeur ne peut rien vous dire sur la probabilité que H_0 soit vraie. Elle ne peut que vous permettre d'évaluer le risque de refuser H_0 à tort.
8. Si on suppose à présent σ inconnu quel nouveau test proposer ?

2 Données réelles

Les données du fichier `apnee.csv` décrivent l'observation de 35 sujets souffrant d'apnée du sommeil (`apnee=1`) et de 65 sujets ne souffrant pas de ce problème (`apnee=0`). Pour chaque sujet ont été observés l'âge, le poids, la taille, le tabagisme (1 si fumeur), le sexe (0 pour les hommes) et le nombre de verres d'alcool consommés par jour. Ces données ont été collectées afin d'évaluer les effets potentiels du sexe, de la consommation d'alcool et de tabac ou du poids sur l'apnée du sommeil.

Exercice 2 : test pour μ

1. Charger les données `apnee.csv` avec la fonction `read.table()` et affecter le `data.frame` à `data`.
2. Extraire du `data.frame` `data` l'échantillon des mesures de la variable `poids` chez les hommes, avec la commande `data[data$sexe==0,"poids"]` et l'affecter à `poidsH`.
3. On supposera que le poids d'un homme suit une loi normale $\mathcal{N}(\mu, \sigma^2)$. Calculer l'estimation sans biais de la moyenne μ et de la variance σ^2 de cet échantillon.
4. Proposer un test sur μ d'égalité avec la valeur $\mu_0 = 87$ contre l'alternative $\mu_0 > 87$ au niveau α pour une collection de valeur de α : 0.01, 0.02, ..., 0.1. Il y aura une décision pour chaque α proposé. Entre quelles valeurs de α observe-t-on un changement de décision ?
5. Calculer la valeur de ce niveau critique α^* appelé p-valeur du test.
6. Que retourne la commande `t.test(poidsH, mu=87, alternative="greater")` ?